

$$\begin{cases} -\sum_{i=1}^{\ell} \lambda_i + \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle \rightarrow \min_{\lambda}; \\ 0 \leq \lambda_i \leq C, \quad i = 1, \dots, \ell; \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0. \end{cases}$$

Решив эту задачу численно относительно  $\lambda_i$ ,  
получаем линейный классификатор:

$$a(\mathbf{x}) = \text{sign} \left( \sum_{i=1}^{\ell} \lambda_i y_i \langle \mathbf{x}_i, \mathbf{x} \rangle - w_0 \right),$$

где  $w_0 = \sum_{i=1}^{\ell} \lambda_i y_i \langle \mathbf{x}_i, \mathbf{x}_j \rangle - y_j$  для такого  $j$ , что  $\lambda_j > 0$ ,  $M_j = 1$

### Определение

Объект  $\mathbf{x}_i$  называется *опорным*, если  $\lambda_i \neq 0$ .

$$\begin{cases} -\sum_{i=1}^{\ell} \lambda_i + \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j K(x_i, x_j) \rightarrow \min_{\lambda}; \\ 0 \leq \lambda_i \leq C, \quad i = 1, \dots, \ell; \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0. \end{cases}$$

Решив эту задачу численно относительно  $\lambda_i$ ,  
получаем линейный классификатор:

$$a(x) = \text{sign}\left(\sum_{i=1}^{\ell} \lambda_i y_i K(x_i, x) - w_0\right),$$

где  $w_0 = \sum_{i=1}^{\ell} \lambda_i y_i K(x_i, x_j) - y_j$  для такого  $j$ , что  $\lambda_j > 0$ ,  $M_j = 1$

## Определение

Объект  $x_i$  называется *опорным*, если  $\lambda_i \neq 0$ .

## Определение

Функция от пары объектов  $K(x, x')$  называется *ядром*, если она представима в виде скалярного произведения

$$K(x, x') = \langle \psi(x), \psi(x') \rangle$$

при некотором преобразовании  $\psi: X \rightarrow H$  из пространства признаков  $X$  в новое *спрямляющее* пространство  $H$ .

## Возможная интерпретация:

признак  $f_i(x) = K(x_i, x)$  — это оценка близости объекта  $x$  к опорному объекту  $x_i$ . Выбирая опорные объектов, SVM осуществляет отбор признаков в линейном классификаторе

$$a(x) = \text{sign} \left( \sum_{i=1}^{\ell} \lambda_i y_i K(x_i, x) - w_0 \right).$$

Ядра в SVM расширяют линейную модель классификации:


- ❶  $K(x, x') = (\langle x, x' \rangle + 1)^d$   
— полиномиальная разделяющая поверхность степени  $\leq d$ ;
- ❷  $K(x, x') = \sigma(\langle x, x' \rangle)$   
— нейронная сеть с заданной функцией активации  $\sigma(z)$   
( $K$  не при всех  $\sigma$  является ядром);
- ❸  $K(x, x') = \text{th}(k_1 \langle x, x' \rangle - k_0), \quad k_0, k_1 \geq 0$   
— нейросеть с сигмоидными функциями активации;
- ❹  $K(x, x') = \exp(-\gamma \|x - x'\|^2)$   
— сеть радиальных базисных функций (RBF ядро);

Гиперплоскость в спрямляющем пространстве соответствует нелинейной разделяющей поверхности в исходном.

Примеры с различными ядрами  $K(x, x')$


линейное

$$\langle x, x' \rangle$$




полиномиальное

$$(\langle x, x' \rangle + 1)^d, \quad d=3$$



гауссовское (RBF)

$$\exp(-\gamma \|x - x'\|^2)$$




Пример из Python scikits learn: <http://scikit-learn.org/dev>


SVM — аппроксимация и регуляризация эмпирического риска:

$$\sum_{i=1}^{\ell} (1 - M_i(w, w_0))_+ + \frac{1}{2C} \|w\|^2 \rightarrow \min_{w, w_0}.$$

большой  $C$   
слабая регуляризация



малый  $C$   
сильная регуляризация



Пример из Python scikits learn: <http://scikit-learn.org/dev>

## Преимущества:

- Задача выпуклого квадратичного программирования имеет единственное решение.
- Выделяется множество опорных объектов.
- Имеются эффективные численные методы для SVM.
- Изящное обобщение на нелинейные классификаторы.

## Недостатки:

- Опорными объектами могут становиться выбросы.
- Нет отбора признаков в исходном пространстве  $X$ .
- Приходится подбирать константу  $C$ .